

Erheben einer Verkehrsstatistik durch Klassifizierung von Verkehrsobjekten unter Verwendung eines neuronalen Netzes

Studienarbeit - T3201

des Studiengangs Informatik

an der Dualen Hochschule Baden-Württemberg Stuttgart

von

Florian Drinkler, Luca Stanger

11. Juni 2021

Bearbeitungszeitraum
Matrikelnummer, Kurs
Ausbildungsfirma
Betreuer

06.10.2020 - 11.06.2021
6653948, 7474265, TINF-18B
Balluff GmbH, camos GmbH, Stuttgart
Sebastian Trost, Telefónica Germany

Sperrvermerk

Der Inhalt dieser Arbeit darf weder als Ganzes noch in Auszügen Personen außerhalb des Prüfungsprozesses und des Evaluationsverfahrens zugänglich gemacht werden, sofern keine anderslautende Genehmigung der Ausbildungsstätte vorliegt.

Stuttgart, 11. Juni 2021

Florian Drinkler, Luca Stanger

Erklärung

Wir versichern hiermit, dass wir unsere Studienarbeit - T3201 mit dem Thema: *Erheben einer Verkehrsstatistik durch Klassifizierung von Verkehrsobjekten unter Verwendung eines neuronalen Netzes* selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt haben. Wir versichern zudem, dass die eingereichte elektronische Fassung mit der gedruckten Fassung übereinstimmt.

Stuttgart, 11. Juni 2021

Florian Drinkler, Luca Stanger

Abstract

Inhaltsverzeichnis

Abkürzungsverzeichnis	VI
Abbildungsverzeichnis	VII
Tabellenverzeichnis	VIII
1 Einleitung	1
1.1 Motivation und Problemstellung	1
1.2 Zielsetzung	1
1.3 Methodik und Aufbau der Arbeit	1
2 Grundlagen und Stand der Forschung	2
2.1 Implementierungsumgebung Jupyter	2
2.2 Bildverarbeitungsalgorithmen mit OpenCV	3
2.3 Maschinelle Lernverfahren	3
2.3.1 Supervised Learning	3
2.3.2 Unsupervised Learning	3
2.3.3 Reinforcement Learning	3
2.4 Datenstromorientierte Programmierung mit TensorFlow	3
2.4.1 Künstliche neuronale Netze	3
2.4.2 Convolutional Neural Networks	4
2.5 Deep Learning mit Keras	6
2.6 Verwandte Arbeiten	6
3 Analyse der Datenströme	7
3.1 Anforderungen an die Analyse	7
3.2 Datenaufbereitung	7
3.2.1 Datenerhebung und Integration	7
3.2.2 Datenberechnung	7
3.2.3 Datenaggregation	7
3.2.4 Datenbereinigung	7
4 Entwicklung des Modells	8
4.1 Vorverarbeitung der Daten	8
4.2 Entwurf eines Netzwerks zur Klassifikation von Objekten	8
4.4 Erheben einer Verkehrsstatistik	8
4.5 Statistische Bewertung des Modells	8
4.5.1 Determination aussagekräftiger Metriken	8

5	Prototypische Implementierung	9
5.1	Aufbau des Prototypen	9
5.2	Modellierung	9
5.3	Deployment	9
5.4	Anpassbarkeit	9
6	Evaluation des Prototypen	10
6.1	Metriken zur Bewertung der Klassifikation	10
6.2	Optimierung des neuronalen Netzes	10
6.3	Evaluierung der Ergebnisse	10
7	Abschluss	11
7.1	Fazit	11
7.2	Ausblick	11
	Literatur	12
	Glossar	14

Abkürzungsverzeichnis

HTML Hypertext Markup Language

PDF Portable Document Format

GPU Graphical Processing Unit

TPU Tensor Processing Unit

CNN Convolutional Neural Network

SVM Support Vector Machine

Abbildungsverzeichnis

2.1	Einzelnes Neuron mit dessen Komponenten	3
2.2	Darstellung der Sigmoid Aktivierungsfunktion	4
2.3	Erzeugen einer Merkmalskarte durch schrittweise Faltung	5

Tabellenverzeichnis

1 Einleitung

In der heutigen Zeit werden Algorithmen immer häufiger eingesetzt, um verschiedenen Personengruppen die Auswertung von Daten leichter zu machen. Maschinelle Lernverfahren bieten mit der Zeit immer fortgeschrittenere Möglichkeiten, unterschiedlichste Alltagssituationen zu analysieren. Im Zusammenhang mit dem Thema Verkehrsanalyse bietet das maschinelle Lernen vielfältige Möglichkeiten zur Verbesserung des öffentlichen Raums. Hauptbestandteil dieser Arbeit soll es sein, eine Verkehrsstatistik unter Verwendung eines Klassifikationsalgorithmus zu erstellen. Die daraus gewonnenen Erkenntnisse werden in dieser Arbeit wiedergegeben. Aus den resultierenden Ergebnissen wird eine einfache Ableitung über das Verkehrsaufkommen erreicht.

1.1 Motivation und Problemstellung

1.2 Zielsetzung

1.3 Methodik und Aufbau der Arbeit

2 Grundlagen und Stand der Forschung

2.1 Implementierungsumgebung Jupyter

Jupyter Notebooks ist eine von der non-profit Organisation Project Jupyter entwickelte Open-Source Lösung zur interaktiven Arbeit mit Dutzenden Programmiersprachen [4]. Der Name Jupyter leitet sich dabei von den drei primären Programmiersprachen Julia, Python und R ab. Jupyter Notebooks ist sprachunabhängig und unterstützt, unter Verwendung des IPython [Kernel](#), die Programmiersprachen Julia, R, Haskell, Ruby und Python [3]. Darüber hinaus werden unterschiedlichste Export Möglichkeiten wie Hypertext Markup Language ([HTML](#)), Portable Document Format ([PDF](#)) und \LaTeX unterstützt. Die in diesem Projekt verwendete Variante von Jupyter Notebooks ist Google Colab, eine speziell für die Python-Entwicklung entworfene Umgebung. Colab Notebooks führen Code auf Cloud-Servern aus und bieten somit unabhängige Vorteile gehosteter Hardware, wie Graphical Processing Units ([GPUs](#)) und Tensor Processing Units ([TPUs](#)) [1].

2.2 Bildverarbeitungsalgorithmen mit OpenCV

2.3 Maschinelle Lernverfahren

2.3.1 Supervised Learning

2.3.2 Unsupervised Learning

2.3.3 Reinforcement Learning

2.4 Datenstromorientierte Programmierung mit TensorFlow

2.4.1 Künstliche neuronale Netze

Die Ursprünge der künstlichen neuronalen Netze lassen sich auf McCulloch et al. im Jahre 1943 zurückführen [7]. Eine von Donald O. Hebb 1949 formulierte Lernregel stellt seither in ihrer allgemeinen Form die Grundlage der künstlichen neuronalen Lernverfahren dar [6].

Ein künstliches neuronales Netz besteht aus einer Eingabeschicht von Neuronen, 1.. n versteckter Schichten und einer letzten Schicht von Ausgangsneuronen. Ein einzelnes Neuron nimmt üblicherweise mehrere Werte x_1, \dots, x_n und einen Bias-Term w_0 als Eingabe und berechnet daraus die Ausgabe $y = h(z)$.




Abbildung 2.1: Einzelnes Neuron mit dessen Eingangsvariablen. Die Aktivierungsfunktion ist beschrieben als h und wird auf die tatsächlichen Eingabe z angewandt. x_1, \dots, x_n repräsentieren die Eingabe von anderen Neuronen innerhalb des Netzes. w_0 wird Bias genannt und repräsentiert ein externes Gewicht [11].

Die Ausgabe h_i des Neurons i in der versteckten Schicht wird beschrieben durch

$$h_i = \varphi\left(\sum_{j=1}^N V_{ij}x_j + \theta_i^{hid}\right) \quad (2.1)$$

wo $\varphi(\cdot)$ die Aktivierungsfunktion, N die Anzahl der Eingangsneuronen, V_{ij} die Gewichte, x_j die Eingabe zum Neuron und θ_i^{hid} der Schwellenwertterm der versteckten Neuronen ist [12, S. 81–100, 8, S. 195–201]. Die Intention der Aktivierungsfunktion $\varphi(\cdot)$ neben der Einführung von Nichtlinearität in das neuronale Netz ist, den Wert eines Neurons zu begrenzen, damit das neuronale Netz nicht durch divergierende Neuronen gelähmt wird. Eine gängige Aktivierungsfunktion ist die Sigmoid Funktion $\sigma(\cdot)$, wie definiert in 2.2.

$$\sigma(u) = \frac{1}{1 + e^{-u}} \quad (2.2)$$

Weitere sigmoide Aktivierungsfunktionen sind der Arkustangens (arctan) und Tangens Hyperbolicus (tanh) [8, S. 195–201]. Sie haben ein ähnliches Ansprechverhalten auf die Eingangswerte wie die Sigmoidfunktion, unterscheiden sich aber in den Ausgangsbereichen.




Abbildung 2.2: Darstellung der Sigmoid Aktivierungsfunktion

2.4.2 Convolutional Neural Networks

Seitdem [AlexNet](#) im Jahre 2012 eine Auszeichnung beim jährlichen Wettbewerb der Benchmark-Datenbank ImageNet erzielte [2], hat sich der Forschungsfokus auf das Themengebiet *Deep Learning* zubewegt [5, 9, 10]. Zuvor waren Support Vector Machines ([SVMs](#)) der prävalierende Ansatz zur Erkennung von Mustern.

Convolutional Neural Networks (CNNs) werden seit 1995 in der digitalen Bildverarbeitung eingesetzt und sind fester Bestandteil des *Deep Learnings*. Es werden Faltmatrizen der Größe 3x3, 5x5, 7x7 bzw. 9x9 eingesetzt, um Bereiche der Eingabematrix sukzessiv zu analysieren. Die dabei verwendeten *convolutional operations* (Faltoperationen) erzeugen rezeptive Felder, die eine Merkmalskarte (*feature map*) des CNN generieren [10]. Die rezeptiven Felder korrespondieren mit einer Region aus dem Originalbild [13].




Abbildung 2.3: Erzeugen einer Merkmalskarte durch schrittweise Faltung

In der Mathematik wird die Faltung als eine Operation auf zwei Funktionen f, g beschrieben, die eine dritte Funktion $f * g$ erzeugt. Die dritte Funktion beschreibt, wie die Form von f durch g verändert oder gefiltert wird. Für eine Position $z_{i,j}$ in der Ausgabe gilt

$$z_{i,j} = b + \sum_{u=0}^{f_h-1} \sum_{v=0}^{f_w-1} x_{i+u,j+v} \cdot w_{u,v} \quad (2.3)$$

worin $z_{i,j}$ die Position innerhalb der Matrix z beschreibt und b der Bias ist. Betrachtet man nun die Position $z_{i,j}$ in der Ausgabe eines Layers gilt

$$z_{i,j} = b + \sum_{u=0}^{f_h-1} \sum_{v=0}^{f_w-1} x_{i',j'} \cdot w_{u,v} \quad \begin{cases} i' = i \cdot s_h + u \\ j' = j \cdot s_w + v \end{cases} \quad (2.4)$$

Die darauffolgende *Volume Convolution* erweitert die Gleichung um einen Parameter k , der die Anzahl der Farbräume in die Gleichung einbezieht. Es gilt

$$z_{i,j,k'} = b_{k'} + \sum_{c=1}^k \sum_{u=0}^{f_h-1} \sum_{v=0}^{f_w-1} x_{i',j',c} \cdot w_{u,v,c,k'} \quad \begin{cases} i' = i \cdot s_h + u \\ j' = j \cdot s_w + v \end{cases} \quad (2.5)$$

Die Anzahl der Parameter eines CNN ist unabhängig von der Eingabe, jedoch abhängig von der Größe des Filters. Allgemein gilt daher

$$\# \text{Params}_{\text{conv}} = (f_w \cdot f_h \cdot k^{l-1} + 1) \cdot k^l \quad (2.6)$$

2.5 Deep Learning mit Keras

2.6 Verwandte Arbeiten

3 Analyse der Datenströme

3.1 Anforderungen an die Analyse

3.2 Datenaufbereitung

3.2.1 Datenerhebung und Integration

3.2.2 Datenberechnung

3.2.3 Datenaggregation

3.2.4 Datenbereinigung

4 Entwicklung des Modells

4.1 Vorverarbeitung der Daten

4.2 Entwurf eines Netzwerks zur Klassifikation von Objekten

4.3

4.4 Erheben einer Verkehrsstatistik

4.5 Statistische Bewertung des Modells

4.5.1 Determination aussagekräftiger Metriken

5 Prototypische Implementierung

5.1 Aufbau des Prototypen

5.2 Modellierung

5.3 Deployment

5.4 Anpassbarkeit

6 Evaluation des Prototypen

6.1 Metriken zur Bewertung der Klassifikation

6.2 Optimierung des neuronalen Netzes

6.3 Evaluierung der Ergebnisse

7 Abschluss

7.1 Fazit

7.2 Ausblick

Literatur

- [1] Google Colab. *Willkommen bei Colaboratory - Colaboratory*. 2021. URL: <https://colab.research.google.com/notebooks/intro.ipynb#scrollTo=0wuxHmx1lTwN>. (abgerufen am 01.02.2021).
- [2] ImageNet. *ImageNet Large Scale Visual Recognition Competition*. 2012. URL: <http://www.image-net.org/challenges/LSVRC/2012/results.html>. (abgerufen am 01.02.2021).
- [3] Project Jupyter. *Jupyter Kernels - jupyter/jupyter*. 2021. URL: <https://github.com/jupyter/jupyter/wiki/Jupyter-kernels>. (abgerufen am 01.02.2021).
- [4] Project Jupyter. *Project Jupyter - Home*. 2021. URL: <https://jupyter.org/>. (abgerufen am 01.02.2021).
- [5] Alex Krizhevsky, Ilya Sutskever und Geoffrey E Hinton. „ImageNet Classification with Deep Convolutional Neural Networks“. In: *Advances in Neural Information Processing Systems*. Hrsg. von F. Pereira et al. Bd. 25. Curran Associates, Inc., 2012, S. 1097–1105. URL: <https://proceedings.neurips.cc/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf>.
- [6] Klaus Mainzer. „Komplexität neuronaler Netze“. In: *Gehirn, Computer, Komplexität*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1997, S. 143–161. ISBN: 978-3-642-60524-6. DOI: [10.1007/978-3-642-60524-6_9](https://doi.org/10.1007/978-3-642-60524-6_9). URL: https://doi.org/10.1007/978-3-642-60524-6_9.
- [7] Warren McCulloch und Walter Pitts. „The Linear theory of Neuron Networks: The Static Problem“. In: *Bulletin of Mathematical Biology* 4.4 (1943), S. 169–175.
- [8] International Workshop on Artificial Neural Networks, Jose Mira und Francisco Sandoval. *From Natural to Artificial Neural Computation - International Workshop on Artificial Neural Networks, Malaga-Torremolinos, Spain, June 7-9, 1995 : Proceedings*. Berlin Heidelberg: Springer Science und Business Media, 1995. ISBN: 978-3-540-59497-0.
- [9] Mohammad Rastegari et al. *XNOR-Net: ImageNet Classification Using Binary Convolutional Neural Networks*. 2016. arXiv: [1603.05279](https://arxiv.org/abs/1603.05279) [cs.CV].
- [10] Olga Russakovsky et al. *ImageNet Large Scale Visual Recognition Challenge*. 2015. arXiv: [1409.0575](https://arxiv.org/abs/1409.0575) [cs.CV].

- [11] David Stutz. „Introduction to Neural Networks“. In: *RWTH Aachen University* (März 2014).
- [12] Sun-Chong Wang. „Artificial Neural Network“. In: *Interdisciplinary Computing in Java Programming*. Boston, MA: Springer US, 2003, S. 81–100. ISBN: 978-1-4615-0377-4. DOI: [10.1007/978-1-4615-0377-4_5](https://doi.org/10.1007/978-1-4615-0377-4_5). URL: https://doi.org/10.1007/978-1-4615-0377-4_5.
- [13] Wei Qi Yan. *Computational Methods for Deep Learning - Theoretic, Practice and Applications*. Singapore: Springer Nature, 2020. ISBN: 978-3-030-61081-4.

Glossar

AlexNet

Ein von Alexander Krizhevsky entworfenes [CNN](#).

Bias

Unabhängiges Gewicht eines neuronalen Netzes.

Kernel

Ein Programm, das den Code des Anwenders ausführt und introspektiert.